Laboratorio de
Aprendizaje Estadístico

Clasificación de la informalidad laboral en México.

Presentado por:

Claudio Alejo Encarnación Martínez (750597)
Alan Jesús Hernández Soto (752714)

Objetivo

El empleo informal es todo trabajo remunerado (ya sea asalariado o por cuenta propia) que no está registrado, regulado ni protegido por los marcos legales o normativos del Estado.



Construir y comparar **tres modelos de clasificación supervisada** (regresión logística con regularización, máquina de vectores de soporte con kernel RBF y perceptrón multicapa), cuyos hiperparámetros se **optimizan mediante optimización bayesiana** con procesos gaussianos, para **clasificar** si una persona ocupada en México tiene un **empleo informal** a partir de los microdatos de la **ENOE del segundo trimestre de 2026**. El trabajo final permite estimar informalidad laboral y desarrollar perfiles en zonas o municipios para un posible desarrollo de nuevas políticas, programas o aciones focalizadas.



Dataset

Resultados del 2ndo Trimestre 2026 de la Encuesta Nacional de Ocupación y Empleo (ENOE) elaborado por el INEGI.

- Recolecta datos demográficos y laborales en hogares mexicanos mediante un cuestionario básico y otro especializado en ocupación para personas de 15 años o más.
- Representa a los 32 estados y las 39 ciudades principales del país.
- Se busca evaluar de forma integral el mercado laboral de México mediante datos económicos, laborales y socio-demográficos.

Análisis del Dataset

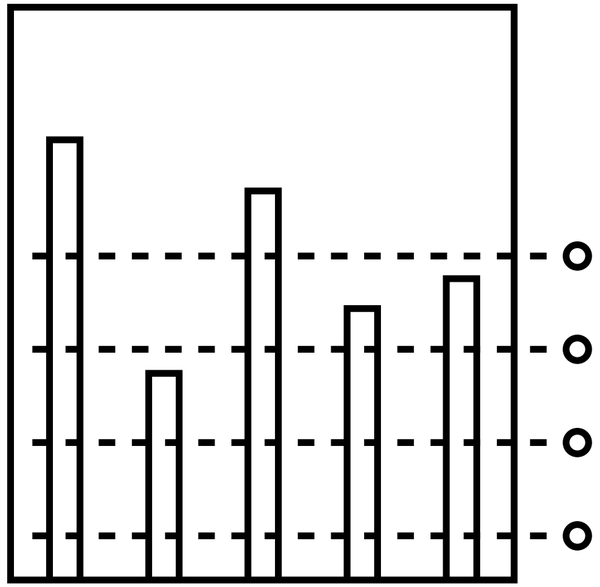
Variable Objetivo: emp_ppal (Formal o Informal) | de 1,2 a 1, 0

Clasifica la condición de informalidad del empleo principal. Se transformó en una variable binaria:

- 1: empleo informal.
- 0: empleo formal.

¿Cómo seleccionamos las variables?

- Elegimos características sociodemográficas, laborales y geográficas que podrían estar asociadas con la informalidad.
- Excluimos variables usadas directamente para definirla, como el acceso a seguridad social.
- Comparamos variables similares para evitar información redundante.



Variables sociodemográficas

Categoría	Variables y significado
Edad	eda: edad de la persona en años.
Escolaridad	anios_esc: años de estudio; niv_ins: nivel de instrucción.
Alfabetización	cs_p12: si sabe leer y escribir un recado.
Asistencia escolar	cs_p17: si asiste actualmente a la escuela.
Perfil personal	sex: sexo; e_con: estado conyugal.

Estas variables describen **características personales y educativas** que pueden estar relacionadas con las oportunidades de empleo.

Variables laborales y geográficas

Grupo	Variables y significado
Jornada	hrsocup: horas trabajadas por semana; dur9c: categoría de duración de la jornada.
Ingreso	ingocup: ingreso mensual por trabajo, usado para crear variables transformadas.
Sector	scian: sector de actividad económica, con mayor detalle que rama.
Localidad	t_loc_tri: tamaño de localidad; ur: ámbito urbano o rural.
Ubicación	geo: municipio en AMG5 y Jalisco; entidad federativa en el conjunto nacional.

Se seleccionó scian porque mejoró el ROC-AUC frente a rama en las pruebas realizadas. Combinar las dos variables no produjo una mejora adicional en esta comparación.

Transformación de Variables

Variable	Transformación	¿Por qué?
emp_ppal	y = 1 informal; y = 0 formal.	Formular una clasificación binaria.
ingocup	log_ing = ln(1 + ingreso).	Reducir la asimetría y permitir ceros.
ingocup	ing_cero = 1 si ingreso = 0.	Identificar registros con ingreso igual a cero.
hrsocup	hrs_cero = 1 si horas = 0.	Identificar registros con cero horas.
cve_mun / cve_ent	Crear la variable geo.	Representar municipio o entidad.
Categóricas	Codificación One-Hot.	Convertir categorías en columnas para los modelos.

En el ingreso, cero puede representar tanto a una persona que no recibe ingresos como a una que no los especificó; por eso no debe interpretarse automáticamente como ausencia real de ingresos.

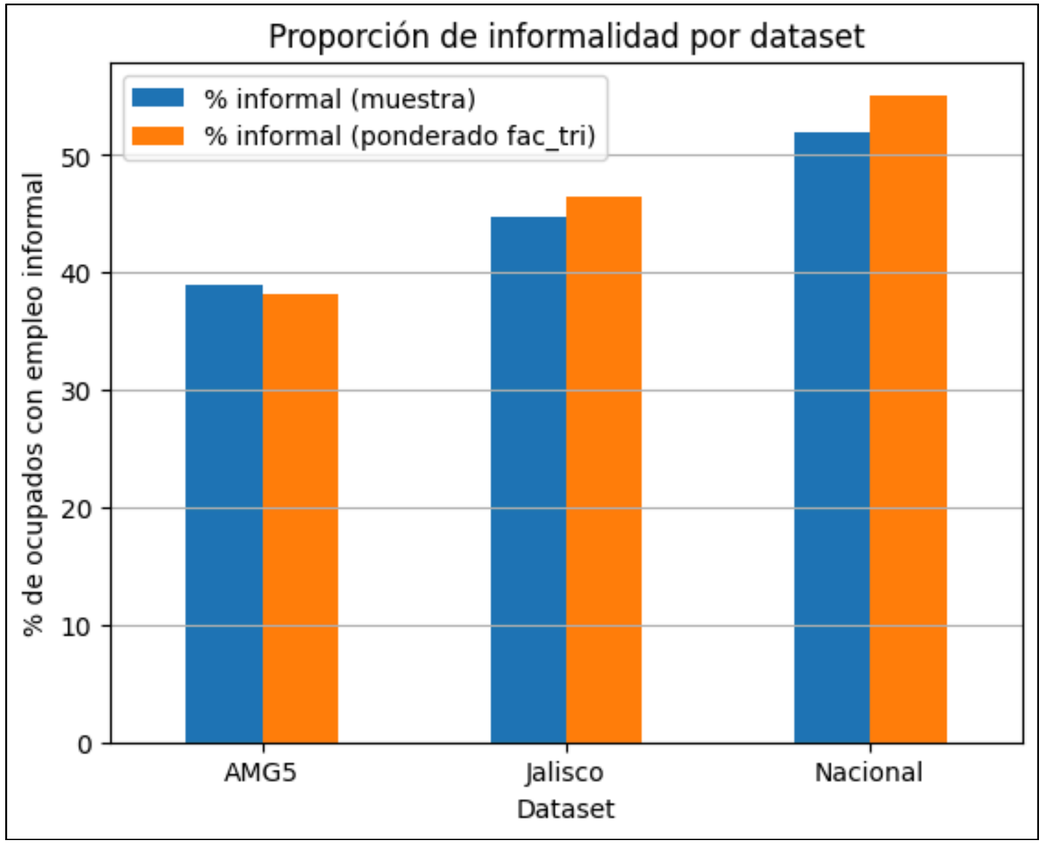
Construcción de conjuntos

Conjunto	Selección geográfica	Registros	% informal
AMG5	Guadalajara, Zapopan, Tlaquepaque, Tonalá y Tlajomulco.	3,959	39.0 %
Jalisco	Todos los registros de la entidad.	5,882	44.8 %
Nacional	Registros de las 32 entidades.	188,673	51.9 %

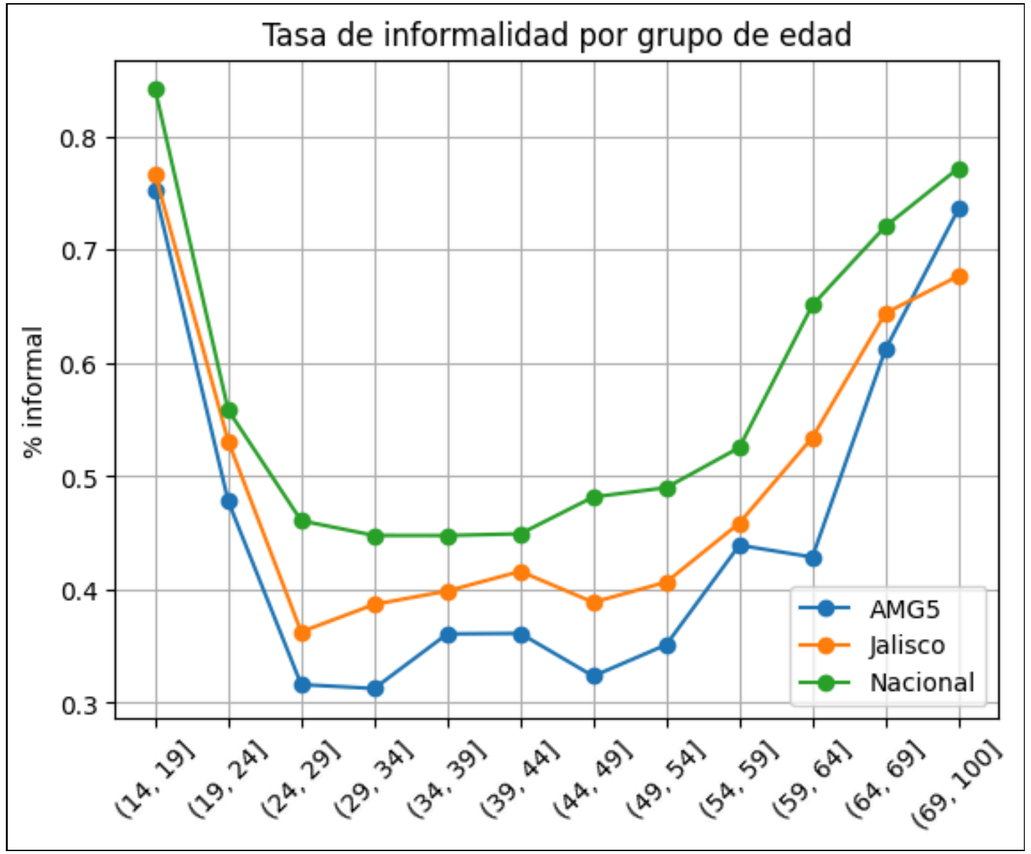
AMG5 ⊂ Jalisco ⊂ Nacional.

EDA

01 | Informalidad por Zona

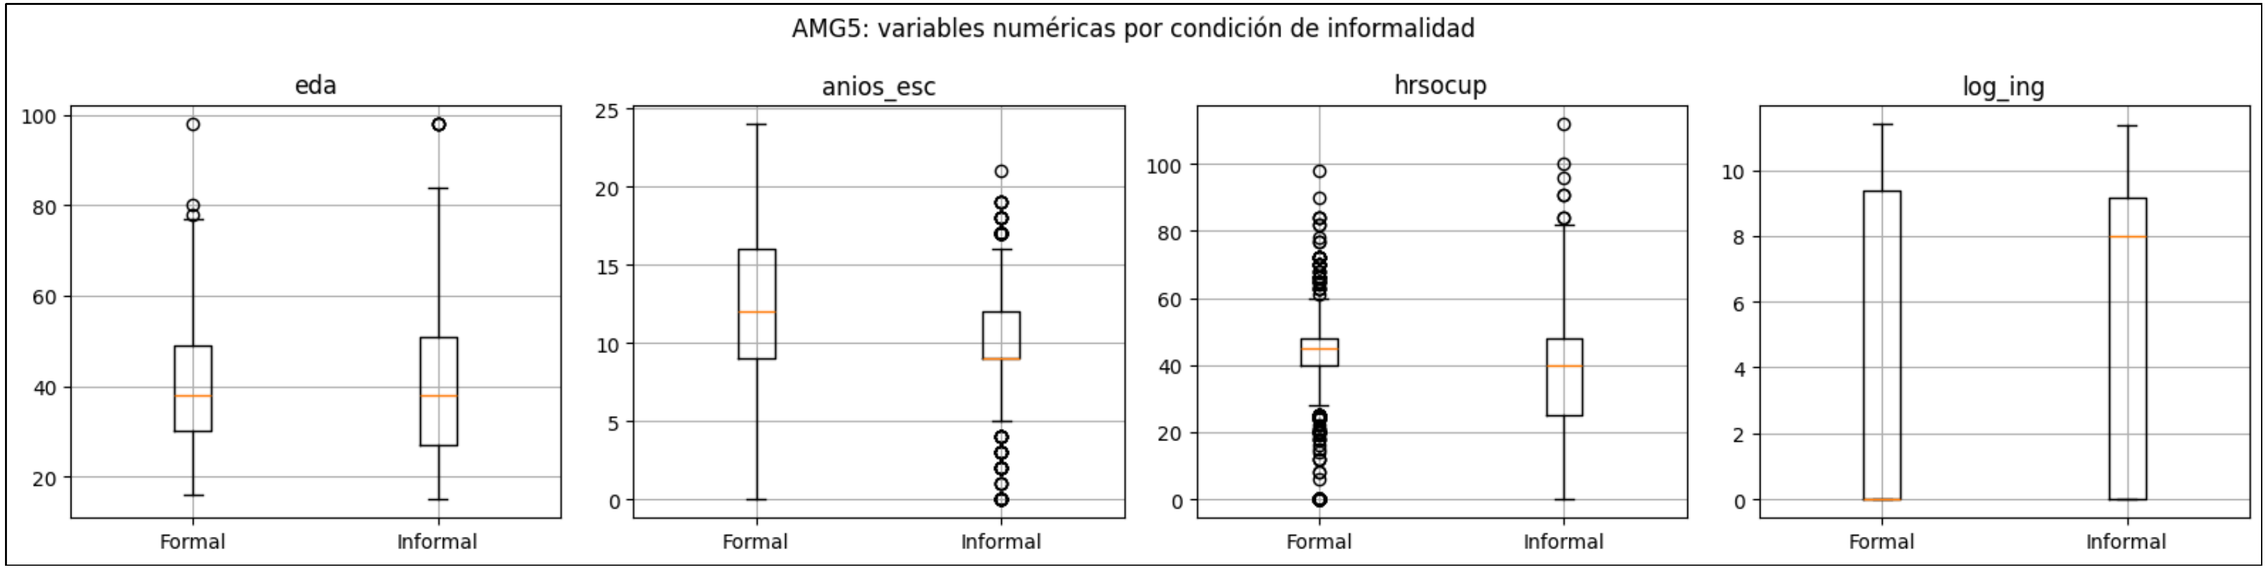


02 | Edad e Informalidad



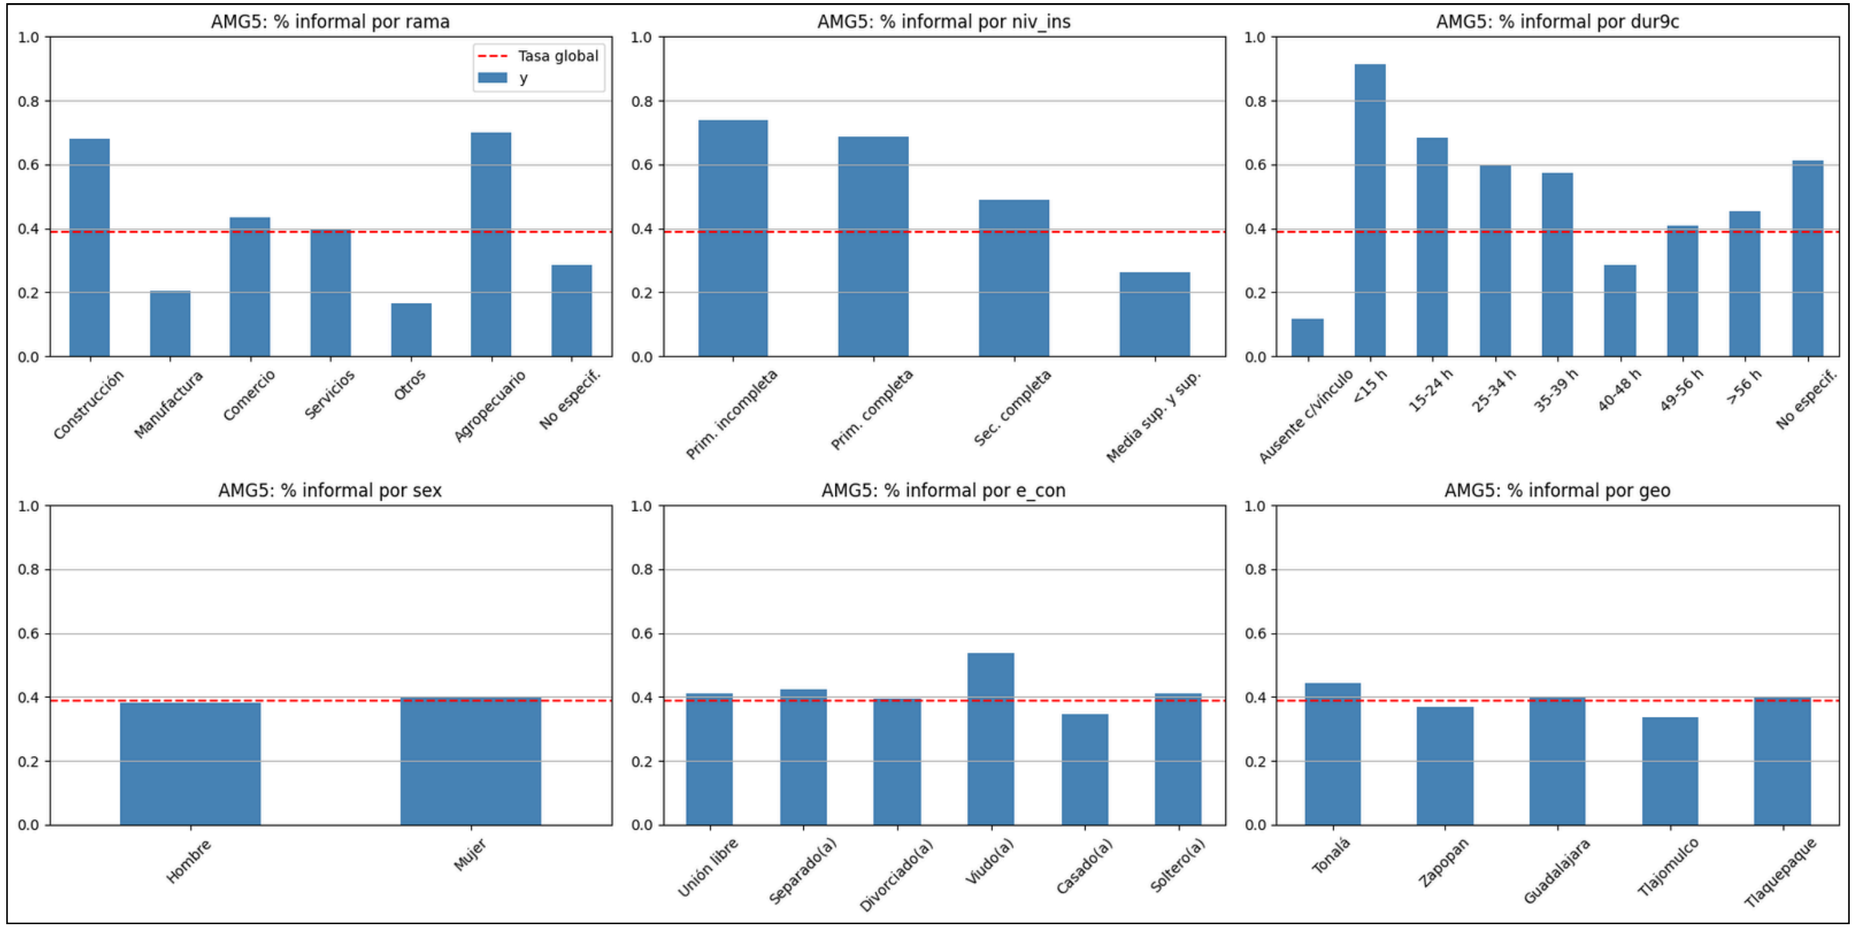
EDA

03 | Tasa de Informalidad por variable numérica



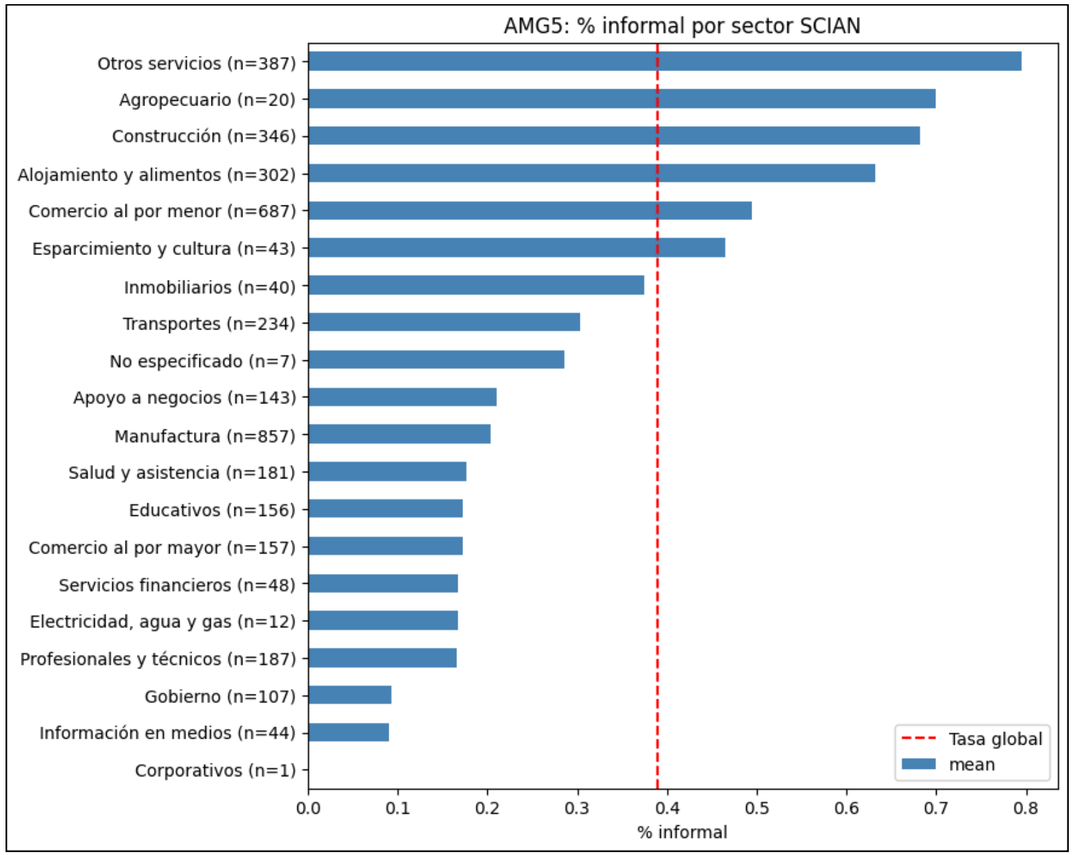
EDA

04 | Tasa de Informalidad por variable categórica

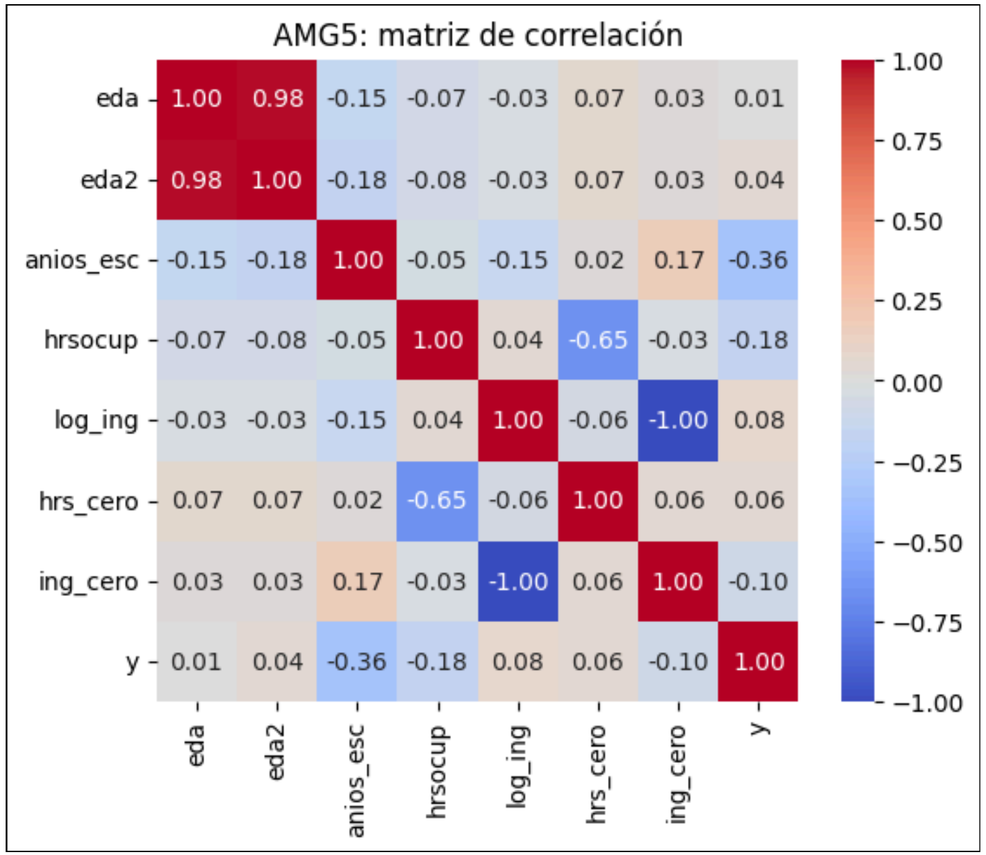


EDA

05 | Sector Económico | AMG5



06 | Correlación de variables | AMG5



Modelos e Hiperparámetros

Regresión logística
Modelo lineal con regularización de red elástica.

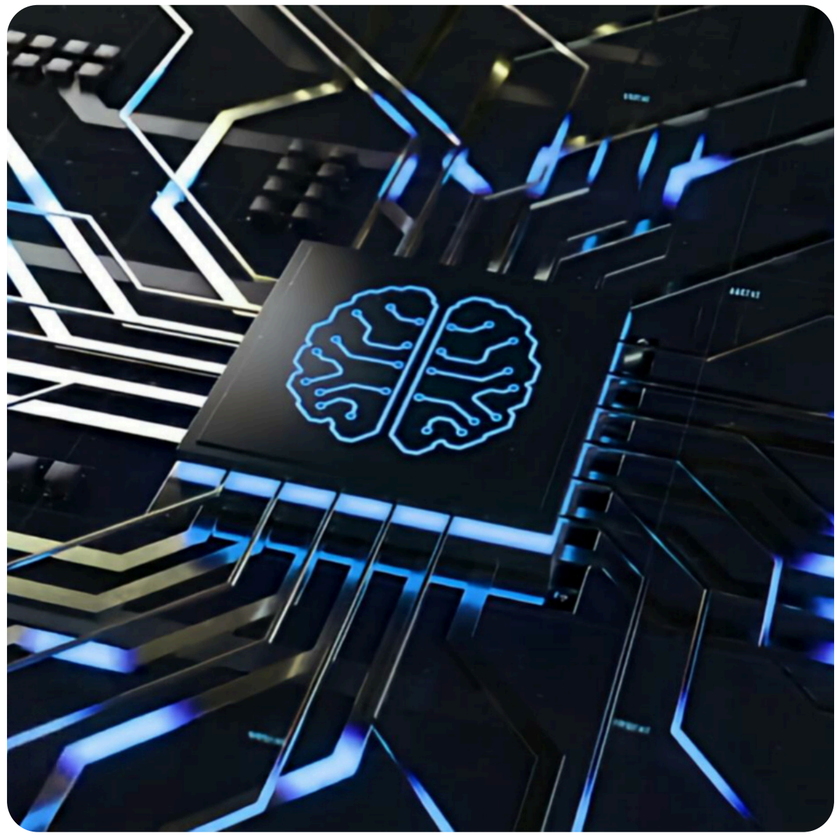
- C: 0.0001 – 100
- l1_ratio: 0 – 1

SVM con kernel RBF
Modelo que permite una frontera de clasificación no lineal.

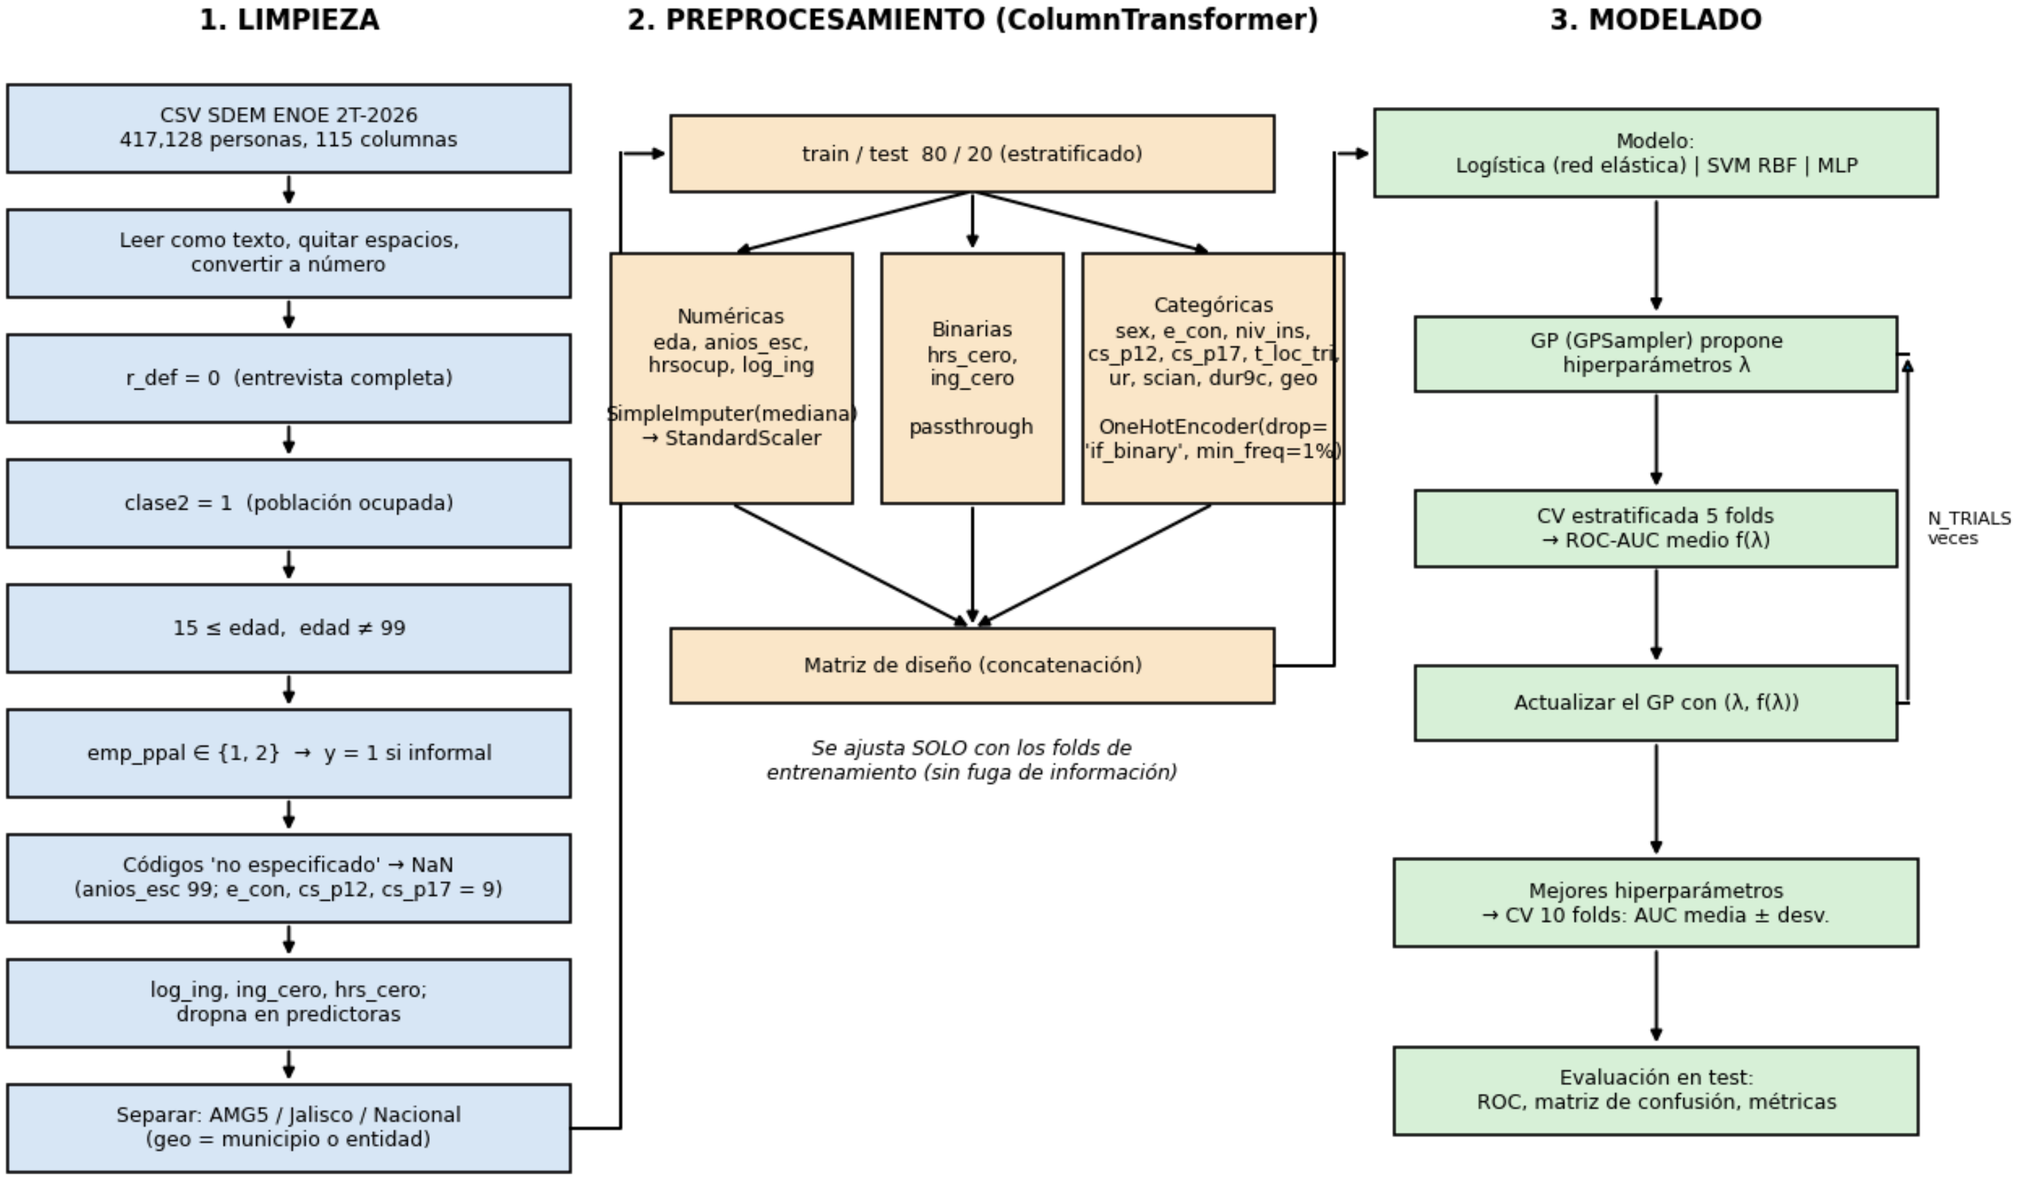
- C: 0.01 – 1,000
- gamma: 0.0001 – 10

Perceptrón multicapa — MLP
Red neuronal con una o dos capas ocultas.

- Capas: 1–2
- neuronas por capa: 5–100
- alpha: 0.00001–1
- tasa de aprendizaje: 0.0001–0.1



Pipeline del proyecto



Resultados - CV

Modelo	AMG5	Jalisco	Nacional
Regresión logística	0.8295 ± 0.0208	0.8455 ± 0.0117	0.8726 ± 0.0022
SVM RBF	0.8308 ± 0.0229	0.8428 ± 0.0111	0.8832 ± 0.0046
MLP	0.8267 ± 0.0219	0.8382 ± 0.0120	0.8914 ± 0.0019

El **ROC-AUC** mide qué tan bien el modelo ordena a una persona informal por encima de una formal. La **media** resume el desempeño entre folds y la **desviación** muestra su variación.

Resultados – Prueba

Modelo	AMG5	Jalisco	Nacional
Regresión logística	0.8513	0.8445	0.8725
SVM RBF	0.8495	0.8434	0.8844
MLP	0.8435	0.8377	0.8923

- **AMG5:** la regresión logística obtuvo el mayor ROC-AUC en prueba: 0.8513.
- **Jalisco:** la regresión logística obtuvo el mayor valor: 0.8445.
- **Nacional:** el MLP alcanzó el mayor ROC-AUC: 0.8923.

Conclusiones

01 — Capacidad de clasificación

Los tres modelos lograron un ROC-AUC superior a 0.82 en las comparaciones de validación cruzada de las tres zonas.

02 — Mejor modelo por zona

En validación cruzada destacó la SVM en AMG5, la regresión logística en Jalisco y el MLP en el conjunto nacional.

03 — Resultados en prueba

La regresión logística obtuvo el mayor ROC-AUC en prueba para AMG5 y Jalisco, mientras que el MLP destacó a nivel nacional.

04 — Alcance y limitaciones

Los modelos identifican patrones predictivos, pero no establecen causas de la informalidad. Las métricas corresponden a la muestra analizada y el modelado no utilizó el factor de expansión.

Gracias!